Análisis de resultados y conclusiones

Objetivo y base del análisis

El análisis describe la aprobación observada, la procedencia educativa, la demanda por carrera y las oportunidades registradas en las pruebas específicas de aspirantes a la Facultad de Ingeniería de la USAC. También evalúa qué aporta consultar la misma información mediante documentos y grafos.

Se utilizaron los diez archivos locales pruebas_especificas_2015.csv a pruebas_especificas_2024.csv, ubicados en datas/ArchivosCSV/. El conjunto está identificado en el repositorio como «Pruebas específicas» del portal de Datos Abiertos de la Facultad. No se verificó nuevamente su procedencia contra el portal externo.

Los años de ingreso abarcan 2015–2024, mientras que las fechas de asignación van del 23 de agosto de 2014 al 15 de enero de 2024. Son conceptos distintos: una asignación puede ocurrir el año anterior al ciclo solicitado. No se dispone de una fecha efectiva de examen que permita sustituirla por la fecha de asignación.

Las cifras del conjunto oficial se recalcularon desde los CSV locales aplicando la deduplicación y las reglas de transformación utilizadas por el sistema. Sus hashes coinciden con los registrados en la verificación analítica disponible. Se contrastaron además respuestas de lectura de la API y el historial de importaciones el 3 de noviembre de 2026. Los porcentajes de las tablas se redondean a dos decimales.

Registros leídos, evaluaciones e identidades

Indicador del conjunto oficial local	Cantidad
Archivos CSV	10
Filas leídas y procesadas, sin encabezados	208.453
Filas rechazadas en esas importaciones	0
Repeticiones de contenido excedentes	834
Evaluaciones únicas después de deduplicar	207.619
Identificadores completos distintos	42.371
Pares identificador/ciclo distintos	56.337
Evaluaciones aprobadas	29.701
Evaluaciones reprobadas	177.918
Resultados desconocidos	0

El historial de importaciones confirma que todas las filas de los diez originales se procesaron en ambos motores. La diferencia 208.453 − 834 = 207.619 explica por qué las filas procesadas superan los documentos únicos. Las repeticiones se conservan como procedencias del mismo documento y no se suman nuevamente en las estadísticas.

Los 42.371 identificadores representan identidades observadas, no una cantidad certificada de personas. Hasta 2021 se utilizan correlativos de 32 caracteres y desde 2022 aparecen correlativos de 20–23. El sistema no une identificadores por prefijo. Una misma persona podría no ser reconocible entre ambos formatos; tampoco se deben sumar aspirantes de grupos distintos para obtener un total global.

Separación de los datos de validación

La base activa consultada contiene 207.622 evaluaciones, tres más que el conjunto oficial deduplicado. El historial identifica dos cargas adicionales llamadas datos_invalidos.csv:

Carga de validación	Leídos	Procesados	Rechazados	Evaluaciones nuevas
Versión de veinte registros	20	2	18	2
Versión de dos registros	2	1	1	1
Total adicional	22	3	19	3

Por tanto, las operaciones consultadas acumulan 208.475 filas leídas, 208.456 procesadas y diecinueve rechazadas, pero estos totales incluyen validación y no describen el conjunto oficial. La copia actual de ese CSV local tiene dos filas; no debe utilizarse para representar también la versión anterior de veinte.

En las respuestas actuales aparecen dos evaluaciones reprobadas adicionales de Matemática para ingreso 2015 y una evaluación sin materia, ciclo ni resultado utilizables. La base activa suma 29.701 aprobadas, 177.920 reprobadas y un resultado desconocido. M06 informa un corte de 207.622 evaluaciones y diecisiete grupos; el conjunto oficial contiene dieciséis categorías de carrera, incluida NINGUNO.

Las tablas analíticas siguientes excluyen esas tres evaluaciones adicionales. Esto explica pequeñas diferencias frente al dashboard actual. No se eliminaron datos ni se realizaron nuevas cargas para obtener las cifras oficiales.

Duplicados y datos incompletos

El identificador de evaluación se calcula con los doce campos de origen y la identidad del aspirante, siguiendo la normalización del ETL. Repetir un archivo reutiliza documentos y relaciones; las ocurrencias originales quedan vinculadas por hash del archivo y número de registro. Sin un identificador oficial de examen, igualdad de contenido no demuestra que dos filas correspondan al mismo evento físico.

Los registros incompletos no se eliminan automáticamente. SIN REGISTRO, SIN DATOS y NINGUNO se conservan como ausencia de información; los cálculos utilizan únicamente los campos válidos que necesitan.

En los CSV originales hay 19.451 filas con nacimiento SIN REGISTRO. Después de deduplicar, 19.404 evaluaciones no tienen una edad utilizable, incluida la exclusión de cuatro evaluaciones con nacimiento 1900 y edades calculadas superiores a cien. Estas cantidades utilizan unidades diferentes y no deben compararse como si ambas contaran documentos únicos con nacimiento ausente.

Desde 2022 existen nombres truncados de carreras y municipios. Se preservan sus textos y claves, sin completar etiquetas por suposición. Los espacios significativos también pueden distinguir categorías aparentemente iguales.

Aprobación y reprobación por materia
M02 y M04 permiten comparar cantidades y tasas por materia sobre evaluaciones únicas.

Materia	Evaluaciones	Aprobadas	Reprobadas	Aprobación
MATEMATICA	123.841	10.900	112.941	8,80 %
COMPUTACION	83.756	18.801	64.955	22,45 %
MATEMATICA ITUGS	22	0	22	0,00 %
Total	207.619	29.701	177.918	14,31 %

La aprobación global observada es 29.701 / 207.619 × 100 = 14,31 %; la reprobación es 85,69 %. Matemática reúne más evaluaciones y una tasa de aprobación inferior a Computación. La diferencia es descriptiva: no demuestra por sí sola la causa ni permite medir dificultad de manera independiente de la población y las oportunidades observadas.
Matemática ITUGS se mantiene como tercera categoría. Sus veintidós evaluaciones constituyen una muestra pequeña; no justifican generalizar el resultado a otros aspirantes o programas.
Las 29.701 aprobaciones son evaluaciones aprobadas, no aspirantes distintos. M03, M07 y M08 cuentan identidades con alguna aprobación dentro del grupo y filtro. Ninguna de esas condiciones demuestra aprobación de todas las materias ni ingreso oficial.

Evolución por año de ingreso
M20 agrupa por ciclo solicitado, no por año de asignación.

Ingreso	Evaluaciones únicas	Aprobadas	Reprobadas	Aprobación
2015	20.274	4.746	15.528	23,41 %
2016	21.987	3.084	18.903	14,03 %
2017	21.399	3.328	18.071	15,55 %
2018	20.680	3.846	16.834	18,60 %
2019	17.835	3.637	14.198	20,39 %
2020	17.665	3.334	14.331	18,87 %
2021	30.644	1.681	28.963	5,49 %
2022	24.231	1.661	22.570	6,85 %
2023	19.047	2.303	16.744	12,09 %
2024	13.857	2.081	11.776	15,02 %

La mayor tasa corresponde a 2015 y la menor a 2021. Este último ciclo también concentra el mayor volumen de evaluaciones. Desde 2022 se observa un aumento de la tasa hasta 2024, que permanece por debajo de 2019 y 2020.
El conjunto no contiene variables suficientes para atribuir las diferencias a cambios de enseñanza, modalidad o condiciones externas. La cantidad de evaluaciones tampoco

equivale al número de aspirantes de cada año, porque incluye materias y oportunidades repetidas.

Distribución por tipo de institución educativa
M01 cuenta identidades distintas dentro de cada tipo; M18 compara resultados de evaluaciones.

Tipo registrado	Evaluaciones únicas	Aspirantes distintos dentro del tipo	Evaluaciones aprobadas	Aprobación
PRIVADO	172.103	35.191	25.786	14,98 %
PUBLICO	28.878	5.654	3.394	11,75 %
POR COOPERATIVA	2.363	466	268	11,34 %
MUNICIPAL	285	58	23	8,07 %
SIN DATOS	3.990	1.006	230	5,76 %

El tipo privado reúne el 82,89 % de las evaluaciones únicas y tiene la mayor tasa observada entre los tipos conocidos. El grupo municipal tiene solo 285 evaluaciones, por lo que su comparación requiere considerar el tamaño de muestra.
Las identidades de la tabla suman 42.375, frente a 42.371 globales, porque algunas aparecen en más de un tipo. Esta distribución describe la procedencia registrada en las evaluaciones; no prueba una relación causal entre tipo de institución y aprobación ni permite comparar establecimientos concretos.

Carreras con mayor demanda observada
El resumen por carrera permite contar cada identidad una vez dentro de una categoría. Entre las categorías conocidas, las cinco con más aspirantes observados son:

Etiqueta de carrera	Aspirantes distintos dentro de la categoría
INGENIERIA EN CIENCIAS Y SISTEMAS	9.185
INGENIERIA CIVIL	7.439
INGENIERIA INDUSTRIAL	7.270
INGENIERIA EN CIENCIAS Y — texto truncado con espacio final	5.660
INGENIERIA QUIMICA	4.023

Se conserva separada la etiqueta truncada: no puede sumarse automáticamente a Sistemas. NINGUNO reúne 6.148 identidades y 20.272 evaluaciones, pero no identifica una carrera conocida y se excluye de este ranking. Una identidad puede haber declarado más de una carrera; las cantidades no son opciones mutuamente excluyentes ni matrículas finales.
M10 limita el análisis a edades calculadas de 16–18 años: Sistemas registra 2.353 identidades; la etiqueta truncada, 1.366; Civil, 1.344; Industrial, 1.343; y Química, 1.166.

Este resultado depende de que la edad y la carrera sean utilizables, por lo que no representa toda la demanda.
M19 añade el departamento de la institución al análisis. Como referencia de la consulta equivalente N03, en Guatemala para ingreso 2024 la etiqueta truncada registra 1.346 aspirantes y la carrera Industrial 463. El departamento corresponde a procedencia educativa y no debe presentarse como residencia.

Edades y oportunidades observadas

La edad calculada es año de ingreso − año de nacimiento; no es una edad exacta porque no se dispone de día y mes de nacimiento. De las evaluaciones oficiales, 188.215 tienen edad utilizable y 19.404 quedan fuera de ese cálculo.
M05, M07 y M06 evitan que quien tenga más evaluaciones pese más en el promedio: eligen una observación por aspirante y grupo, priorizando ciclo, asignación, oportunidad e identificador más recientes. Si esa observación no tiene edad utilizable, se excluye sin rellenarla desde otro ciclo. Por ejemplo, el resumen de Sistemas presenta 20,28 años de promedio, con 8.558 identidades en la muestra y 627 excluidas. No se trata de la edad media de todas las personas que ingresaron a esa carrera.
M14 cuenta oportunidades distintas dentro de cada combinación aspirante/ciclo/materia:

Materia	Grupos aspirante/ciclo	Promedio de oportunidades distintas observadas
MATEMATICA	55.865	2,22
COMPUTACION	45.476	1,84
MATEMATICA ITUGS	14	1,57

Matemática tiene el mayor promedio observado. Esto puede analizarse junto a su menor aprobación, pero no demuestra que todos los intentos de cada aspirante estén presentes. En 49.303 de los 101.355 grupos, la cantidad de oportunidades distintas difiere del ordinal máximo; en 43.049 no aparece la oportunidad 1. Por ello, una fila con oportunidad 4 no prueba cuatro intentos registrados. M16 exige el valor literal 1 para identificar reprobación en primera oportunidad y no utiliza simplemente la menor oportunidad disponible.

Aporte de MongoDB y Neo4j

Las consultas MongoDB permiten comparar unidades diferentes sin confundirlas: evaluaciones por materia, identidades por procedencia, resultados por ciclo y oportunidades por aspirante/ciclo/materia. Los historiales M11/M15 permiten revisar registros concretos y las fuentes que explican los agregados. La colección resumen_carrera conserva un corte identificable; su aviso de actualización evita tratarlo como una consulta siempre calculada sobre el origen actual.
Neo4j permite seguir conexiones explícitas entre aspirante, evaluación, materia, carrera y procedencia. N01 organiza el historial por ciclo; N02 compara aprobación con carrera conocida; N03 cuenta aspirantes por carrera y departamento; N04 identifica reprobaciones seguidas de aprobación en un ordinal mayor; N05 presenta caminos de procedencia municipal compartida.
La verificación de grafos conservada en el repositorio, calculada sobre los diez originales, documenta 27.973 parejas de evaluaciones en N04 correspondientes a 13.438 identidades

distintas. Son parejas, no personas adicionales ni una tasa de recuperación. El ordinal mayor no equivale por sí mismo a una fecha de examen posterior.
N02 considera 187.347 evaluaciones oficiales con carrera representada y deja fuera las 20.272 sin carrera conocida. Ese universo es menor que el de una consulta documental general. N05 utiliza un máximo de 25 caminos por página; su cantidad de nodos visibles no mide el tamaño total de la población relacionada. Compartir municipio no demuestra misma institución específica ni relación personal.

Limitaciones de interpretación
- Los cambios de formato de correlativo impiden certificar una identidad global entre todos los años.
- Las etiquetas truncadas y los espacios significativos fragmentan categorías; fusionarlas sin evidencia alteraría la fuente.
- Los registros sin edad o procedencia utilizable limitan la cobertura de ciertos análisis. Conservarlos no autoriza a completar sus valores.
- Las tasas corresponden a evaluaciones observadas y no a admisión oficial, desempeño futuro ni causalidad educativa.
- Las oportunidades y fechas disponibles no garantizan un historial completo de exámenes.
- Los grupos de aspirantes pueden superponerse por carrera, institución, materia o ciclo.
- La aplicación activa incluye datos de validación. Sus totales globales no deben citarse como si contuviera únicamente los originales.
- Las cifras históricas de verificación de grafos no se presentan como un inventario actual de nodos y relaciones. No se realizó un recuento directo completo de ambos motores ni una nueva ejecución integral de N04 en esta revisión.

Conclusiones

1. El conjunto oficial local contiene 208.453 filas que se reducen a 207.619 evaluaciones por deduplicación. Conservar la procedencia permite explicar esa diferencia sin perder las ocurrencias originales.
2. La aprobación observada es 14,31 %. Computación presenta una tasa mayor que Matemática; la categoría ITUGS es demasiado pequeña para generalizaciones amplias. Estos resultados describen evaluaciones y no admisiones.
3. El comportamiento por ciclo es desigual: 2021 combina el mayor volumen con la menor aprobación, y entre 2022 y 2024 aumenta la tasa. Los datos no permiten establecer las causas de esa evolución.
4. La procedencia privada concentra la mayor parte de las evaluaciones y Sistemas encabeza la demanda entre las etiquetas completas. El tamaño de los grupos, sus superposiciones y los textos truncados deben acompañar cualquier comparación.
5. Las edades aproximadas y las oportunidades distintas son útiles si se informa su cobertura. Excluir solo el cálculo no utilizable conserva información que sigue siendo válida para otros análisis.
6. MongoDB facilita agregaciones y trazabilidad documental; Neo4j complementa el análisis mediante historiales y recorridos de relaciones. La coincidencia de identidad y evaluación entre motores permite relacionar ambos enfoques, siempre respetando sus filtros y universos de consulta.
7. Separar los tres documentos adicionales de validación es necesario para comunicar resultados oficiales coherentes. La base activa y el conjunto original son universos diferentes, aunque las diferencias cuantitativas sean pequeñas.

Referencias del proyecto

- Consultas MongoDB y reglas de cálculo (../consultas/mongodb.md)
- Consultas Neo4j y resultados de contraste (../consultas/neo4j.md)
- Scripts de lectura y contraste en datas/analisis/profile_dataset.py, verify_analytics.py y verify_graph.py
- API de lectura: /api/imports, /api/analytics/ y /api/graph/

La lectura de los CSV y de la API permitió verificar las cifras principales sin modificar las bases. No se ejecutó verify_analytics.py como programa completo, porque también actualiza el resumen. Los resultados históricos de Neo4j se identifican expresamente como evidencia conservada y no como una medición nueva.